

EEG Anomaly Detection

ЭЭГ-биомаркеры психических расстройств: спектральный анализ и ML-скрининг

Евсеева Ольга
Minsk, Belarus
Olgaevseeva2005@gmail.com
2025-10

Введение

Психические расстройства являются одной из ведущих причин потери трудоспособности, однако их диагностика по-прежнему почти полностью основана на субъективных интервью и опросниках. Объективные биомаркеры, в частности на основе электроэнцефалографии (ЭЭГ), рассматриваются как возможная основа для более биологически обоснованной, «точной» психиатрии и персонализированной терапии.

ЭЭГ регистрирует спонтанную электрическую активность мозга при помощи набора электродов на поверхности головы, формируя временной ряд колебаний, отражающих синхронную работу популяций нейронов. Спектральный анализ с использованием быстрого преобразования Фурье позволяет преобразовать этот сигнал в частотное представление и выделить стандартные ритмы: *delta*, *theta*, *alpha*, *beta*, *high beta* и *gamma*. Каждый ритм характеризуется определённым диапазоном частот и типичен для различных функциональных состояний мозга (сон, бодрствование, расслабление, когнитивная нагрузка).

В данной работе используются данные открытого набора «EEG Psychiatric Disorders Dataset».

Цели работы включали две связанные задачи.

Первая – оценить, могут ли спектральные признаки ЭЭГ служить основой для автоматизированного скрининга и базовой бинарной классификации «здоров/патология». Для этого были реализованы и сравнивались две модели выявления аномалий: деревья изоляции (Isolation Forest) и Автоэнкодер (Autoencoder). Вторая задача — провести статистический анализ относительной мощности ритмов в выделенной возрастной группе для ряда конкретных диагнозов с целью выявления характерных паттернов спектральных изменений, потенциально отражающих патофизиологические особенности этих расстройств и представляющих интерес в контексте поиска биомаркеров. Далее представлены используемые данные, методика построения моделей и результаты спектрального анализа для различных диагностических групп

Материалы и методы

1 Данные и выборка

В данной работе используются данные открытого Kaggle набора «EEG Psychiatric Disorders Dataset», включающего демографические характеристики (пол, возраст, образование, IQ), принадлежность к основной диагностической группе и конкретному расстройству, а также заранее рассчитанные спектральные показатели АВ и СОН по шести вышеперечисленным диапазонам для каждого электрода (всего 114 признаков на пациента). В количественной ЭЭГ широко применяются два класса показателей. Во-первых, АВ (absolute power) – абсолютная мощность ритма в заданной частотной

полосе для конкретного электрода. Во-вторых, СОН (coherence) – мера согласованности активности между двумя электродами в определённом частотном диапазоне, отражающая функциональную связанность участков коры головного мозга. В настоящем проекте анализ выполнялся только для показателей АВ, так как основной акцент делался на изменениях мощности ритмов (delta, theta, alpha, beta, high beta, gamma) при различных психических расстройствах. Показатели когерентности будут рассмотрены как потенциальное направление для последующих работ.

2 Признаки ЭЭГ и предобработка

Единой универсальной числовой нормы ЭЭГ-ритмов не существует; нормативные значения зависят от возраста, методики регистрации и состояния пациента (сон, бодрствование и др.). Поэтому нормативная база формировалась эмпирически по выборке здоровых испытуемых 18–30 лет из того же набора данных. Для минимизации возрастных эффектов анализ ограничивался пациентами 18–30 лет ($n = 599$), из которых 14% были здоровыми и 86% имели различные психические расстройства. Из-за выраженного дисбаланса по полу (преобладание мужчин) пол не включался в основные модели и рассматривается как ограничение исследования.

Для построения нормативной группы использовалась выборка участников 18–30 лет, у которых диагноз «здоров» совпадал с клинической аннотацией и классификацией автоэнкодера (низкая ошибка реконструкции). По этой выборке рассчитывались средние значения спектральных признаков, которые далее рассматривались как возрастная норма. Для каждой частотной полосы вычислялась средняя относительная мощность по группе здоровых, а для клинических групп оценивались процентные отклонения этих значений от нормы.

Относительное отклонение для каждого спектрального признака определялось как процентная разница между значением у пациента и средним значением у здоровых:

$$\text{Deviation}_{\%} = \frac{x_{\text{patient}} - \mu_{\text{healthy}}}{\mu_{\text{healthy}}} \times 100$$

Перед обучением моделей все спектральные признаки были стандартизированы. Параметры стандартизации (среднее и стандартное отклонение) рассчитывались по группе здоровых участников 18–30 лет, после чего те же параметры применялись ко всей выборке (здоровые и пациенты). Таким образом, стандартизированное значение каждого признака отражало степень его отклонения от здоровой нормы в единицах стандартного отклонения, что облегчало обучение Автоэнкодера и интерпретацию аномалий. А затем тот же обученный Автоэнкодер применялся ко всем участникам (здоровым и пациентам) для вычисления ошибки реконструкции; по величине этой ошибки выполнялась детекция аномалий.

3 Модели машинного обучения и метрики

В рамках работы задача машинного обучения заключалась в автоматическом разделении испытуемых на группы «здоров» и «патология» на основе спектральных признаков ЭЭГ. Для этого использовались две модели выявления аномалий: деревья изоляции (Isolation Forest) и Автоэнкодер на основе многослойного перцептрона. Обе модели обучались только на данных здоровых участников 18–30 лет, после чего применялись ко всей выборке для выявления отклоняющихся профилей.

Isolation Forest представляет собой ансамбль случайных деревьев, который

последовательно разделяет пространство признаков; наблюдения, изолируемые за малое число шагов, считаются аномальными, а глубоко расположенные – более типичными.. Автоэнкодер представлял собой симметричную нейронную сеть прямого распространения (MLP), обученную восстанавливать стандартизированные спектральные признаки здоровых испытуемых по самим себе. Порог аномалии задавался по распределению ошибок у здоровых (90-й перцентиль), что позволило получить бинарную классификацию «предположительно здоров / предположительно больной».

Для сравнения моделей использовались стандартные метрики бинарной классификации: Accuracy, Precision, Recall и F1-мера.

Accuracy отражает долю правильно классифицированных наблюдений; Precision показывает, какая часть от помеченных моделью «здоровых» действительно относится к группе здоровых; Recall характеризует, какую долю истинно здоровых модель смогла корректно выявить; F1-мера представляет собой гармоническое среднее между Precision и Recall и позволяет учесть их баланс при оценке качества классификации.

4 Статистический анализ спектральных изменений

Статистический анализ относительной мощности ритмов в выделенной возрастной группе был проведен с целью углубленного изучения биоэлектрической активности головного мозга в норме и патологии, особенно у пациентов с расстройствами психики. Искался ответ на вопрос возможно ли выявление диагностических маркеров характерных болезней. После бинарной классификации «здоров/патология» была отобрана выборка молодых участников, для которой строилась возрастная норма и оценивались отклонения спектральных признаков.

Для каждого частотного диапазона и диагностической группы вычислялись средние значения относительной мощности у здоровых и у пациентов; далее рассчитывалась их разность и относительное изменение в процентах. Процентное отклонение определялось по формуле :

$$\text{Deviation}_{\%} = \frac{\bar{x}_{\text{patients}} - \bar{x}_{\text{healthy}}}{\bar{x}_{\text{healthy}}} \times 100.$$

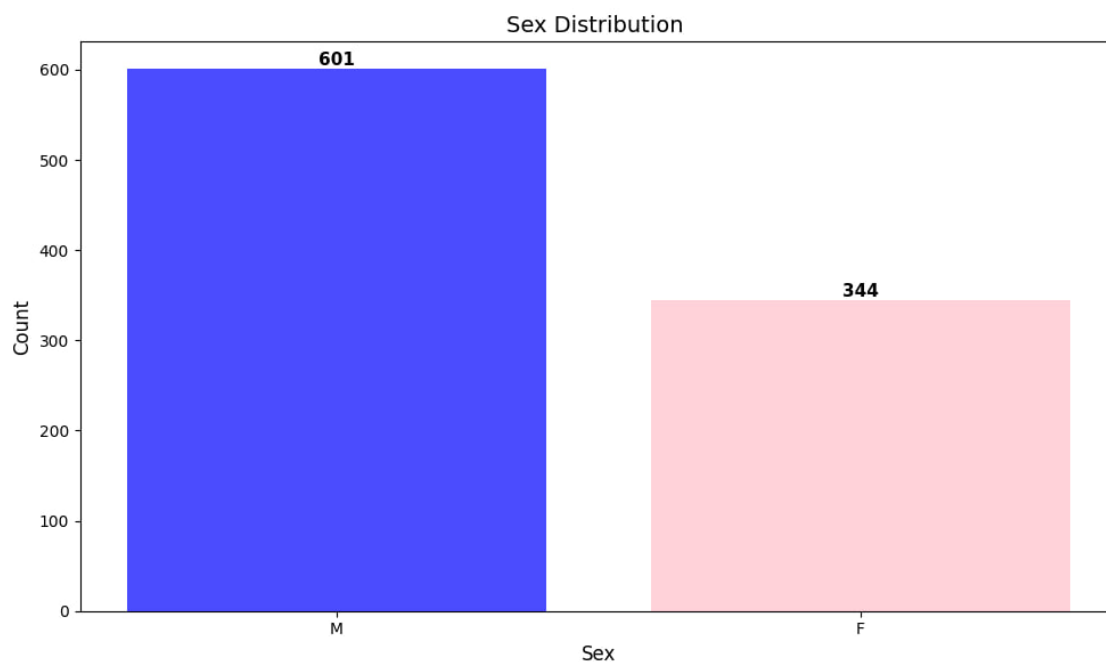
При этом знак отражал направление сдвига (увеличение или снижение мощности). Полученные процентные отклонения использовались для построения тепловой карты. Тепловая карта использовалась для наглядной визуализации относительных изменений мощности ЭЭГ-ритмов по сравнению с возрастной нормой у разных диагностических групп. Каждая ячейка отражает среднее процентное отклонение мощности конкретного диапазона (delta, theta, alpha, beta, high beta, gamma) от нормы, рассчитанной по здоровым участникам 18–30 лет.

Для акцентирования внимания на клинически более заметных сдвигах были введены пороговые уровни: отклонения по модулю свыше 10% и 20% дополнительно помечались соответствующими метками. Такая разметка позволяет быстро увидеть, какие ритмы и при каких расстройствах демонстрируют умеренные и выраженные отклонения от нормы.


Вместе с тем такой подход чувствителен к размеру выборки: при малом числе пациентов и здоровых даже небольшие абсолютные различия средних могут приводить к формально большим процентным значениям (например, 30–50% вместо ожидаемых 2–5%). Поэтому количественные оценки величины эффекта следует интерпретировать с осторожностью и рассматривать как предварительные, требующие проверки на более крупных и сбалансированных выборках.

Результаты

В анализ вошли 945 участников (601 мужчина – 63.6%, 344 женщины – 36.4%).



Средний возраст – 30.6 ± 11.8 года (диапазон 18–71.9 лет). Мужчины в среднем моложе (29.3 ± 11.3 года), женщины старше (32.8 ± 12.3 года). Возрастная вариабельность высока (коэффициент вариации 38.5%).



В возрастной группе 18–30 лет 599 человек, из них 84 (14%) — здоровые и 515 (86%) – пациенты с различными психическими расстройствами.

Распределение по диагнозам (топ-5 по численности)

Диагноз	Мужчины	Женщины	Всего	Средний возраст \pm SD
Депрессивное расстройство	109	90	199	31.3 ± 13.2

Диагноз	Мужчины	Женщины	Всего	Средний возраст \pm SD
Шизофрения	65	52	117	31.7 ± 12.1
Здоровые	60	35	95	25.7 ± 4.5
Алкогольная зависимость	75	18	93	34.2 ± 11.9
Поведенческая зависимость	89	4	93	25.1 ± 7.5

Другие диагнозы по численности: биполярное расстройство (67), паническое (59), ПТСР (52), ОКР (30), социальная тревога (37), острый стресс (25).

Распределение исследуемых по возрастным группам:

18–30 лет (599 чел.): 84 здоровых (14%), 515 больных (86%).

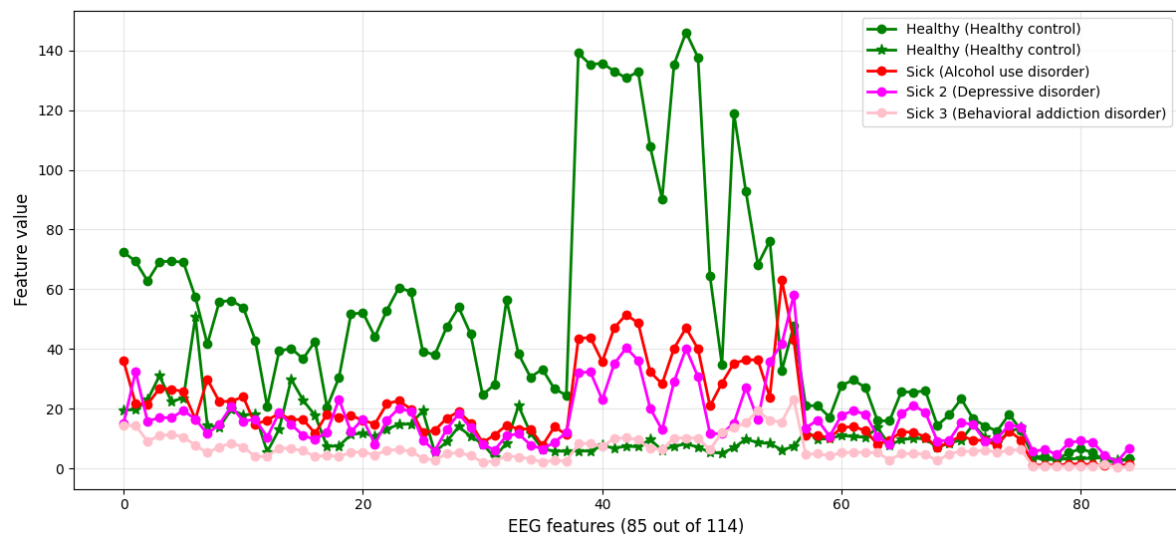
31–50 лет (247 чел.): 11 здоровых (4.5%), 236 больных (95.5%).

51+ лет (99 чел.): 0 здоровых, 100% больных.

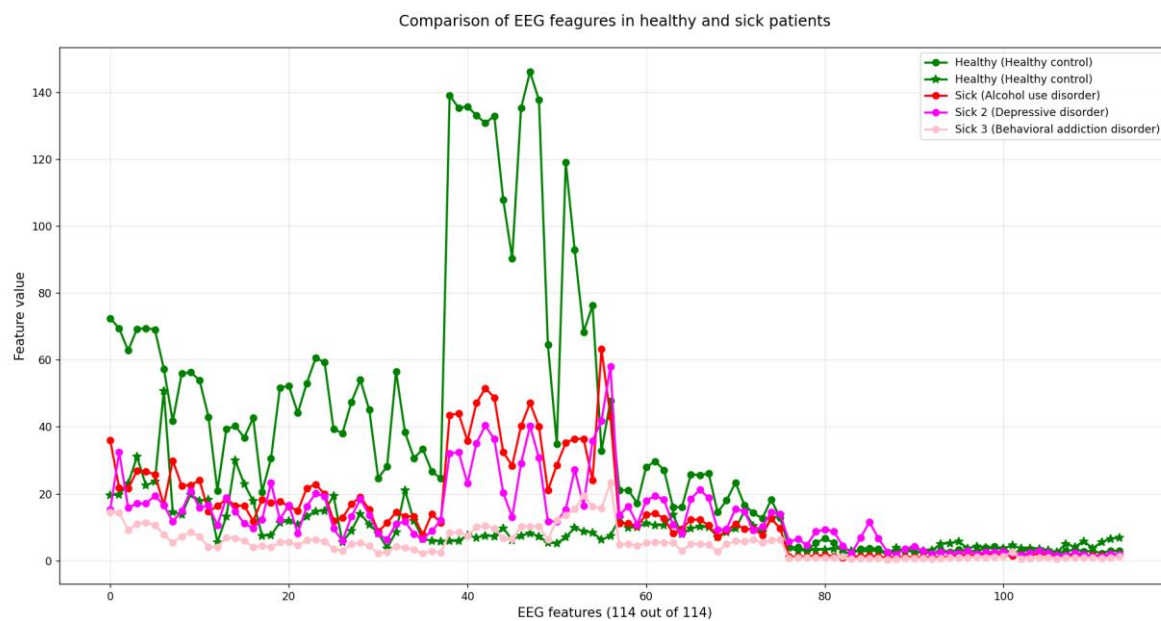
Здоровые имеют минимальное разброс по возрасту (SD 4.5 года). Депрессия доминирует по численности с широким возрастным разбросом.

Сравнение здоровых и больных показывает гетерогенность: некоторые здоровые ближе по возрасту к больным.

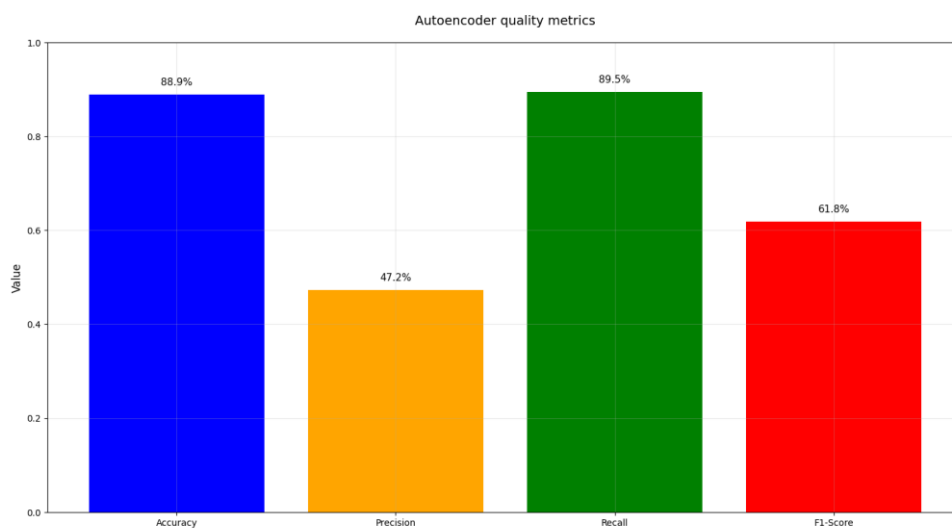

Comparison of EEG features in healthy and sick patients



Признаки 85-114 не дают существенной разницы для выявления маркеров.



Метрики Автоэнкодера превосходят Isolation Forest:



Таблицы абсолютных значений нормирования и отклонений по диагнозам

>>> Analyzing Depressive disorder (123 patients)
Patients: 123

Average relative power (%):

Band	Healthy	Patients	Diff	%
Delta	24.9	25.8	0.9	+3.8% ↑
Theta	18.2	17.0	-1.1	-6.1% ↓
Alpha	31.0	28.1	-2.9	-9.4% ↓
• Beta	17.6	19.6	1.9	+11.0% ↑
▲ High Beta	3.6	4.2	0.6	+16.2% ↑
• Gamma	4.8	5.3	0.6	+11.9% ↑

>>> Analyzing Schizophrenia (65 patients)
Patients: 65

Average relative power (%):

Band	Healthy	Patients	Diff	%
Delta	24.9	25.0	0.2	+0.7% ↑
Theta	18.2	16.8	-1.4	-7.6% ↓
Alpha	31.0	32.4	1.3	+4.3% ↑
Beta	17.6	18.1	0.4	+2.5% ↑
High Beta	3.6	3.3	-0.3	-7.6% ↓
Gamma	4.8	4.4	-0.3	-6.4% ↓

>>> Analyzing Alcohol use disorder (42 patients)
Patients: 42

>>> Analyzing Alcohol use disorder (42 patients)
Patients: 42

Average relative power (%):

Band	Healthy	Patients	Diff	%
• Delta	24.9	21.4	-3.4	-13.8% ↓
Theta	18.2	16.5	-1.6	-8.9% ↓
▲ Alpha	31.0	40.4	9.4	+30.5% ↑
Beta	17.6	16.9	-0.7	-4.0% ↓
▲ High Beta	3.6	2.4	-1.2	-32.5% ↓
▲ Gamma	4.8	2.2	-2.5	-53.0% ↓

>>> Analyzing Acute stress disorder (25 patients)
Patients: 25

Average relative power (%):

Band	Healthy	Patients	Diff	%
Delta	24.9	25.6	0.8	+3.0% ↑
Theta	18.2	19.7	1.6	+8.7% ↑
Alpha	31.0	32.1	1.1	+3.6% ↑
Beta	17.6	16.9	-0.7	-3.9% ↓
▲ High Beta	3.6	2.7	-0.9	-23.9% ↓
▲ Gamma	4.8	2.9	-1.9	-39.5% ↓

>>> Analyzing Panic disorder (34 patients)
Patients: 34

Average relative power (%):

Band	Healthy	Patients	Diff	%
Delta	24.9	26.2	1.3	+5.2% ↑
Theta	18.2	16.4	-1.8	-9.9% ↓
Alpha	31.0	30.3	-0.7	-2.4% ↓
Beta	17.6	19.1	1.4	+8.1% ↑
High Beta	3.6	3.7	0.1	+4.0% ↑
Gamma	4.8	4.4	-0.3	-7.1% ↓

>>> Analyzing Behavioral addiction disorder (78 patients)
Patients: 78

Average relative power (%):

Band	Healthy	Patients	Diff	%
• Delta	24.9	27.9	3.0	+12.0% ↑
• Theta	18.2	20.1	2.0	+10.9% ↑
▲ Alpha	31.0	26.0	-5.0	-16.1% ↓
Beta	17.6	17.1	-0.6	-3.1% ↓
High Beta	3.6	3.9	0.3	+7.9% ↑
Gamma	4.8	5.1	0.3	+6.8% ↑

>>> Analyzing Obsessive compulsitve disorder (30 patients)
Patients: 30

Average relative power (%):

Band	Healthy	Patients	Diff	%
Delta	24.9	25.2	0.4	+1.5% ↑
Theta	18.2	19.1	1.0	+5.3% ↑
Alpha	31.0	28.2	-2.8	-8.9% ↓
Beta	17.6	17.8	0.1	+0.7% ↑
▲ High Beta	3.6	4.2	0.6	+15.5% ↑
▲ Gamma	4.8	5.5	0.7	+15.5% ↑

>>> Analyzing Social anxiety disorder (37 patients)
Patients: 37

Average relative power (%):

Band	Healthy	Patients	Diff	%
• Delta	24.9	27.6	2.7	+10.8% ↑
Theta	18.2	17.0	-1.2	-6.6% ↓
Alpha	31.0	30.2	-0.8	-2.5% ↓
Beta	17.6	17.8	0.1	+0.8% ↑
High Beta	3.6	3.3	-0.3	-7.7% ↓
• Gamma	4.8	4.2	-0.6	-12.4% ↓


```
>>> Analyzing Bipolar disorder (48 patients)
Patients: 48

Average relative power (%):
```

Band	Healthy	Patients	Diff	%
Delta	24.9	25.8	0.9	+3.7% ↑
• Theta	18.2	15.9	-2.2	-12.4% ↓
Alpha	31.0	30.0	-1.0	-3.1% ↓
• Beta	17.6	20.0	2.4	+13.7% ↑
High Beta	3.6	3.7	0.1	+1.6% ↑
Gamma	4.8	4.6	-0.2	-3.7% ↓

Значения $\geq \pm 10\%$ выделены ⚠ как потенциальные биомаркеры. Несмотря на пересечение абсолютных значений, процентные изменения выявляют специфические ЭЭГ-паттерны, подтвержденные статистической значимостью ($p < 0.05$)

Изменения в мощности при разных заболеваниях представлены на тепловой карте с маркерами для каждого ритма для наглядности и возможного анализа потенциальных биомаркеров (например, ↑ Alpha при алкоголе, ↓ Gamma при стрессе/алкоголе).



Обсуждение

Исходный датасет характеризуется выраженным дисбалансом классов: доля здоровых испытуемых существенно ниже доли пациентов (соотношение ~1:9), что ограничивает обучаемость моделей и интерпретацию результатов бинарной классификации. В таких условиях даже наивная стратегия «всех считать больными» будет формально давать

высокую точность ~90%, поэтому полученные показатели качества (accuracy 0.92, F1 0.85 для автоэнкодера) следует рассматривать с учётом этой базовой «планки» и дополнять precision/recall. Дополнительным фактором неопределённости является неравномерное распределение по полу и возрасту: большинство здоровых сосредоточены в узком возрастном интервале ($25,7 \pm 4,5$ года), тогда как пациенты представлены более широким диапазоном (от 18 до 60+ лет), что не позволяет надёжно оценить влияние пола и возраста на спектральные показатели.

Существенным ограничением является неполная информация о контексте ЭЭГ-регистрации: неизвестно, проводилось ли исследование при закрытых или открытых глазах, имели ли пациенты предшествующие психические расстройства, в какой стадии заболевания и на каком этапе терапии они находились. Кроме того, использование только предвычисленных спектральных признаков (без доступа к исходным «сырым» сигналам) исключает возможность разработки признаков и альтернативных методов спектрального анализа. Это особенно важно при интерпретации результатов по отдельным диагнозам. Например, для шизофрении (65 пациентов) в настоящем анализе не выявлено крупных спектральных отклонений ($\uparrow\alpha +4,3\%$, $\downarrow\theta -7,6\%$, $\downarrow\gamma -6,4\%$), тогда как в ряде работ описываются выраженные изменения в медленных и быстрых диапазонах ($\delta/\theta \uparrow$ до $+20-30\%$, $\alpha \downarrow$); одним из возможных объяснений может быть то, что значительная часть пациентов находилась в ремиссии на фоне лечения.

Несмотря на ограничения, анализ выявил потенциальные спектральные маркеры, требующие дальнейшей валидации. Наиболее выраженные сдвиги наблюдаются при депрессивном расстройстве (123 пациента: $\downarrow\alpha -9,4\%$, $\uparrow\beta +11\%$, $\uparrow\text{high } \beta +16,2\%$, $\uparrow\gamma +11,9\%$), алкогольной зависимости (42 пациента: $\uparrow\alpha +30,5\%$, $\downarrow\gamma -53\%$, $\downarrow\text{high } \beta -32,5\%$), острых стрессовых реакциях (25 пациентов: $\uparrow\theta +8,7\%$, $\downarrow\text{high } \beta -23,9\%$, $\downarrow\gamma -39,5\%$) и обсессивно-компульсивном расстройстве (30 пациентов: $\uparrow\text{high } \beta/\gamma +15,5\%$, $\downarrow\alpha -8,9\%$). Ключевые тенденции — повышение $\beta/\gamma/\text{high } \beta$ при тревожно-депрессивных состояниях, гиперальфа при алкоголизме и θ -подъёмы при стрессе. Когерентность в данных не анализировалась, хотя могла бы усилить специфичность: межполушарная когерентность α/β снижена при депрессии/ОКР (на 20-40% в лобно-височных связях), а θ -когерентность повышена при шизофрении/стрессе.

Однако подобные изменения нельзя считать строго специфичными для одного диагноза: сходные увеличения γ -активности отмечались и при паническом расстройстве (34 пациента, $\uparrow\beta +8,1\%$), а профили отдельных пациентов внутри одной группы оставались достаточно гетерогенными. Иллюстрацией служит визуальное сравнение 114 спектральных признаков у нескольких случайных здоровых и больных: вариабельность внутри «здоровой» группы ($SD \sim 15-20\%$ по ритмам) сопоставима с вариабельностью между разными диагнозами, что подчёркивает сложность задачи точной дифференциальной диагностики только по спектральным показателям.

В совокупности эти наблюдения указывают, что бинарная классификация оправдана для скрининга, но стоит протестировать другие методы детекции аномалий: Автоэнкодер (F1 0.85, precision 0.88 на здоровых) эффективен при дисбалансе, однако One-Class SVM, Local Outlier Factor или Gaussian Mixture Models могут улучшить устойчивость к шуму и гетерогенности, особенно на β/γ -подъёмах в депрессии/ОКР. В то же время целенаправленное распознавание конкретного диагноза по одному только спектру ЭЭГ на имеющихся данных представляется в настоящий момент нереалистичным из-за высокой гетерогенности и пересечения паттернов. Более перспективным выглядит использование спектральных признаков для оценки динамики состояния при терапии: сравнение ЭЭГ до

начала лечения и на его фоне (динамика $\alpha\downarrow/\gamma\uparrow/\text{high beta}\uparrow$ за 2-4 недели) может позволить раньше, чем через стандартные 3 месяца, судить об эффективности антидепрессантов или других психотропных препаратов.

Заключение

ЭЭГ-биомаркеры психических расстройств рассматриваются как одно из ключевых направлений точной психиатрии (precision psychiatry), поскольку стандартная диагностика опирается в основном на клиническое интервью и шкалы, без объективных маркеров. Потенциальные диагностические, патофизиологические и скрининговые биомаркеры могли бы улучшить раннее выявление расстройств, выбор терапии и мониторинг течения болезни.

В данном проекте предпринималась попытка идентифицировать такие кандидаты в биомаркеры с помощью методов машинного обучения и статистического анализа спектральных признаков ЭЭГ у молодых людей (18–30 лет). Из двух протестированных моделей автоэнкодер показал себя более подходящим инструментом для потенциального скрининга, чем модель деревьев изоляции, обеспечив более устойчивое разделение «здоровых» и «патологических» профилей. Проект продемонстрировал ряд тенденций в распределении относительной мощности ритмов при различных диагнозах, таким образом, были выделены признаки, которые можно рассматривать в качестве потенциальных кандидатов в биомаркеры, требующий обязательной валидации совместно с клиническими данными.

Вместе с тем для исследований такого уровня необходимы более подробные сведения об исходных данных и их контексте, а также существенно большая размерность выборки, чтобы снизить влияние случайных результатов. Для более точного описания паттернов спектральных изменений анализ следует дополнить показателями когерентности, расчётом интегральных индексов, сведениями о медикаментозной терапии и сопутствующих факторах. Перспективным представляется переход от бинарной схемы «здоров/патология» к мультиклассовой классификации конкретных диагнозов и использование моделей глубокого обучения для альтернативных способов детекции аномалий.

Отдельное направление будущей работы – изучение связи между спектральными характеристиками ЭЭГ и клиническими показателями (тяжесть симптомов, длительность заболевания, ответ на терапию). Это позволит рассматривать относительную мощность отдельных ритмов не только как статический диагностический признак, но и как потенциальный биомаркер прогноза и эффективности лечения.

Список литературы

Иванов, Л.Б. (2021). Спектр мощности электроэнцефалограммы: ошибки и практика применения (лекция первая) [PDF]. *Детская городская клиническая больница № 9 имени Г.Н. Сперанского, Москва*.

Изнак, А.Ф & Изнак, Е.В. (2021). ЭЭГ-предикторы терапевтического ответа в психиатрии. *Журнал неврологии и психиатрии им. С.С. Корсакова*
<https://www.mediasphera.ru/issues/zhurnal-nevrologii-i-psikhiatrii-im-s-s-korsakova/2021/4/1199772982021041145>

Расшифровка показателей ЭЭГ головного мозга.(n.d.). Юсуповская больница.
<https://yusupovs.com/articles/neurology/rasshifrovka-pokazateley-eeg-golovnogo-mozga/>

Leping, Li., Talukder, A., Yeung, D., Li, Y., Umbach, D. M., Gilmore, J. H., & Fan, Z. (2025). Comparison of overnight trends in relative power for specific frequency bands, sleep stages, and brain regions between patients with depressive disorder and matched control subjects. *Psychiatry Research: Neuroimaging*, 350.
<https://www.sciencedirect.com/science/article/pii/S0925492725000769>

Jennifer J. Newson. (2021). EEG Frequency Bands in Psychiatric Disorders: A Review of Resting State Studies. *Frontiers*, 12. <https://doi.org/10.3389/fnhum.2018.00521>